

Provider 与本地缓存 Trace 对账报告

审计日期：2026-07-31。冻结时间：2026-07-31T08:44:29.779175+00:00。范围：gpt-5.6-terra 与 /v1/responses 使用账单。

结论：已捕获调用的 token 记录正确。 573 条调用在未缓存输入、输出、缓存读取和缓存创建四项上逐笔完全一致。

需要修正：cache_hit_ratio 将“缓存创建”误计为“缓存命中”。 本样本仅影响 1 条缓存创建调用，但字段语义应调整。

600 CSV 调用数	573 逐笔完全匹配，95.50%	27 仅见于账单，未见本地 trace	66.98% 账单加权缓存读取命中率
-----------------------------------	---	---	--

逐笔校验结果

匹配键为四项 token 的统一口径；重复键按请求时间最近者配对。573 条匹配的时间误差中位数为 59.8ms，P95 为 226.7ms，最大为 1.163s。

字段	573 条匹配调用：CSV	本地 trace 统一口径	结果
未缓存输入	10,063,982	10,063,982	一致
输出	184,920	184,920	一致
缓存读取	20,036,736	20,036,736	一致
缓存创建	3,530	3,530	一致

字段口径

Provider CSV	本地 trace	正确对应
Input Tokens	input_tokens	本地 input_tokens 是总 prompt token，等于 CSV Input Tokens 加 Cache Read Tokens 加 Cache Creation Tokens。
Cache Read Tokens	cache_read_tokens	数值逐笔一致；它才是“命中”的 token。
Cache Creation Tokens	cache_write_tokens	数值逐笔一致；它代表写入缓存，不是命中。

命中率审计

Provider 全量账单的加权读取命中率为 66.98%。已匹配的本地调用按同一口径为 66.56%。

当前代码使用的公式：

```
(cache_read_tokens + cache_write_tokens) / input_tokens
```

正确的“缓存命中率”应为：

```
cache_read_tokens / input_tokens
```

异常调用 run_id 为 ms8oe745-apb7t5：输入 3,530，读取 0，创建 3,530。本地记录为 100% 命中，实际读取命中应为 0%。

未匹配项与边界

- 27 条账单调用未找到同时间窗的本地 gpt-5.6-terra trace，总计未缓存输入 280,369、缓存读取 950,912、输出 13,174。
- 时间窗内没有“仅本地 trace”的调用。因而本地采集没有虚构调用；缺口更像同一 API key 的其他来源调用，或本地 trace 未落盘。
- 本地 trace 不保存 provider request ID、API key 或 IP，无法仅依这些文件对 27 条缺口做来源归因。

建议

- 把 cache_hit_ratio 改为只使用 cache_read_tokens；保留 cache_write_tokens 作为独立的“缓存创建率/写入量”。
- 看板汇总命中率使用 token 加权值，而不是逐调用简单平均，以避免小调用放大影响。
- 如需账单全量归因，trace 增加脱敏 request ID 与 endpoint 关联字段。

证据：用户提供的 usage_2026-07-31_to_2026-07-31.csv；本地 logs/cache-trace/2026-07-31 中位于 CSV 时间窗的 gpt-5.6-terra trace。原始 CSV 未被修改。